מתודולוגיות עבודה ב-DS

דגשים בתהליך העבודה - הרצת אלגוריתמים

תוכן עניינים

- Test Harness
- K-Fold Cross Validation
- Hyperparameters
- דגשים לסיווג
  - Confusion Matrix
  - Receiver operating characteristic
  - Area under the ROC Curve
- Ensembles

Test Harness

- בכדי להבין איזה אלגוריתם פותר את הבעיה בצורה הטובה ביותר יש לבצע את הבדיקות כך שיתאפשר להעריך את ביצועי המכונה גם במקרי אמת
- לצורך כך יש לממש בדיקות באופן כזה שיאפשרו להעריך ביצועים של מכונות שונות
- ניתן לממש Test Harness ע"י חלוקה נכונה של ה-Data עליו מבוצע הבדיקות
- מימוש של Test Harness יכול להיעשות במס' צורות
  - חלוקה ל-Train & Test
  - חלוקה ל-Train, Cross & Test
  - K-Fold Cross Validation
- ההרצה הסופית מבוצעת על ה-Test בלבד למניעת leakage

K-Fold Cross Validation

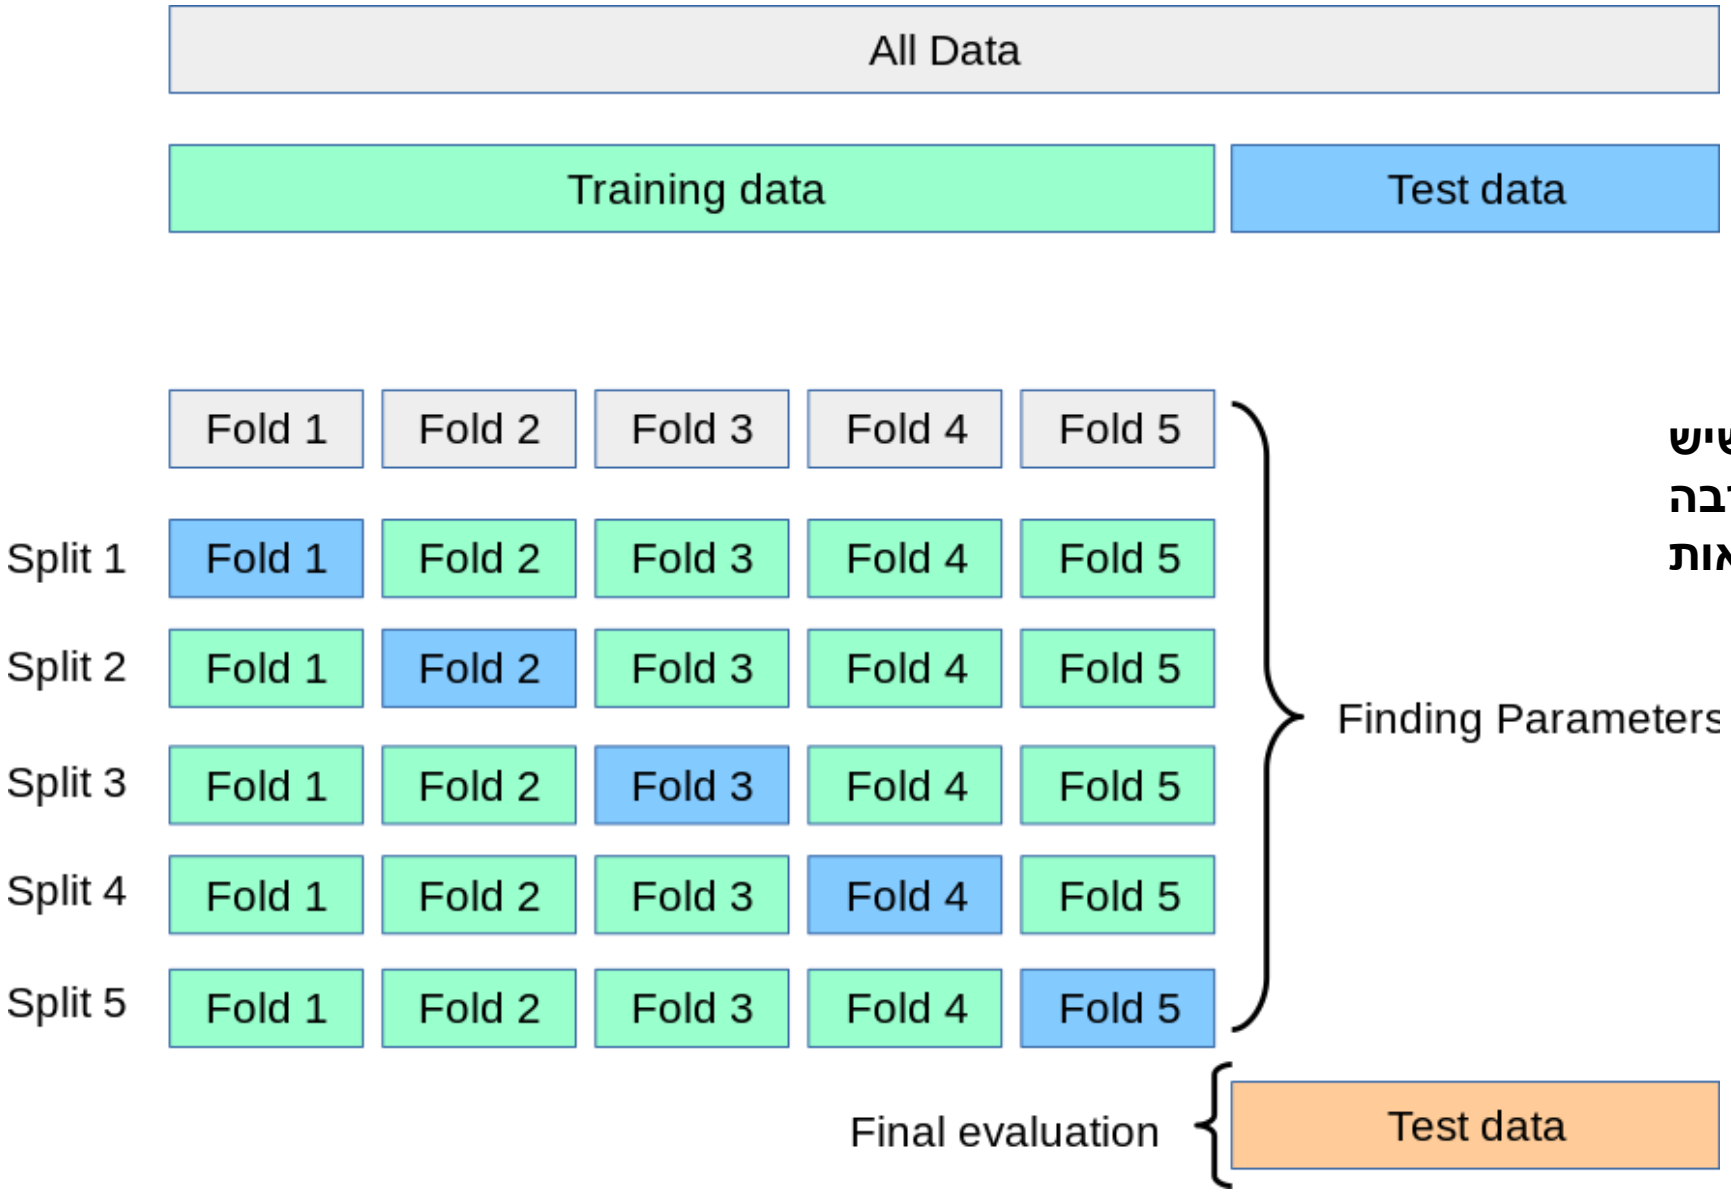

- מתאים לבעיות שיש בהם הרבה דוגמאות

K-Fold Cross Validation

```
x, y = load_iris(return_X_y=True)
clf = svm.SVC(kernel='linear', C=1, random_state=0)
scores = cross_validate(clf, x, y, cv=5, scoring='accuracy')
print("Test Score")
print(scores['test_score'])

print("Accuracy: %0.2f (+/- %0.2f)" % (scores['test_score'].mean(),
scores['test_score'].std() * 2))
```

K-Fold Cross Validation

sklearn.model_selection.cross_val_score

sklearn.model_selection. **cross_val_score** (*estimator*, *X*, *y=None*, *groups=None*, *scoring=None*, *cv='warn'*, *n_jobs=None*, *verbose=0*, *fit_params=None*, *pre_dispatch='2*n_jobs'*, *error_score='raise-deprecating'*) ¶ [source]

Hyperparameters

- מטרת ה- Hyperparameters היא לימוד הפרמטרים הבונים את המודל ומועברים אליו, שאינם נלמדים במסגרת המודל, לדוגמא: C , Kernel & Gamma במודל של SVC
- הלימוד של הפרמטרים מבוצע ע"י הרצה של כל הקומבינציות האפשריות של הפרמטרים, והבאת הציון הגבוה ביותר
- חובה לבצע Hyperparameters למציאת התוצאה הטובה ביותר עבור ה- Cross Validation

Hyperparameters

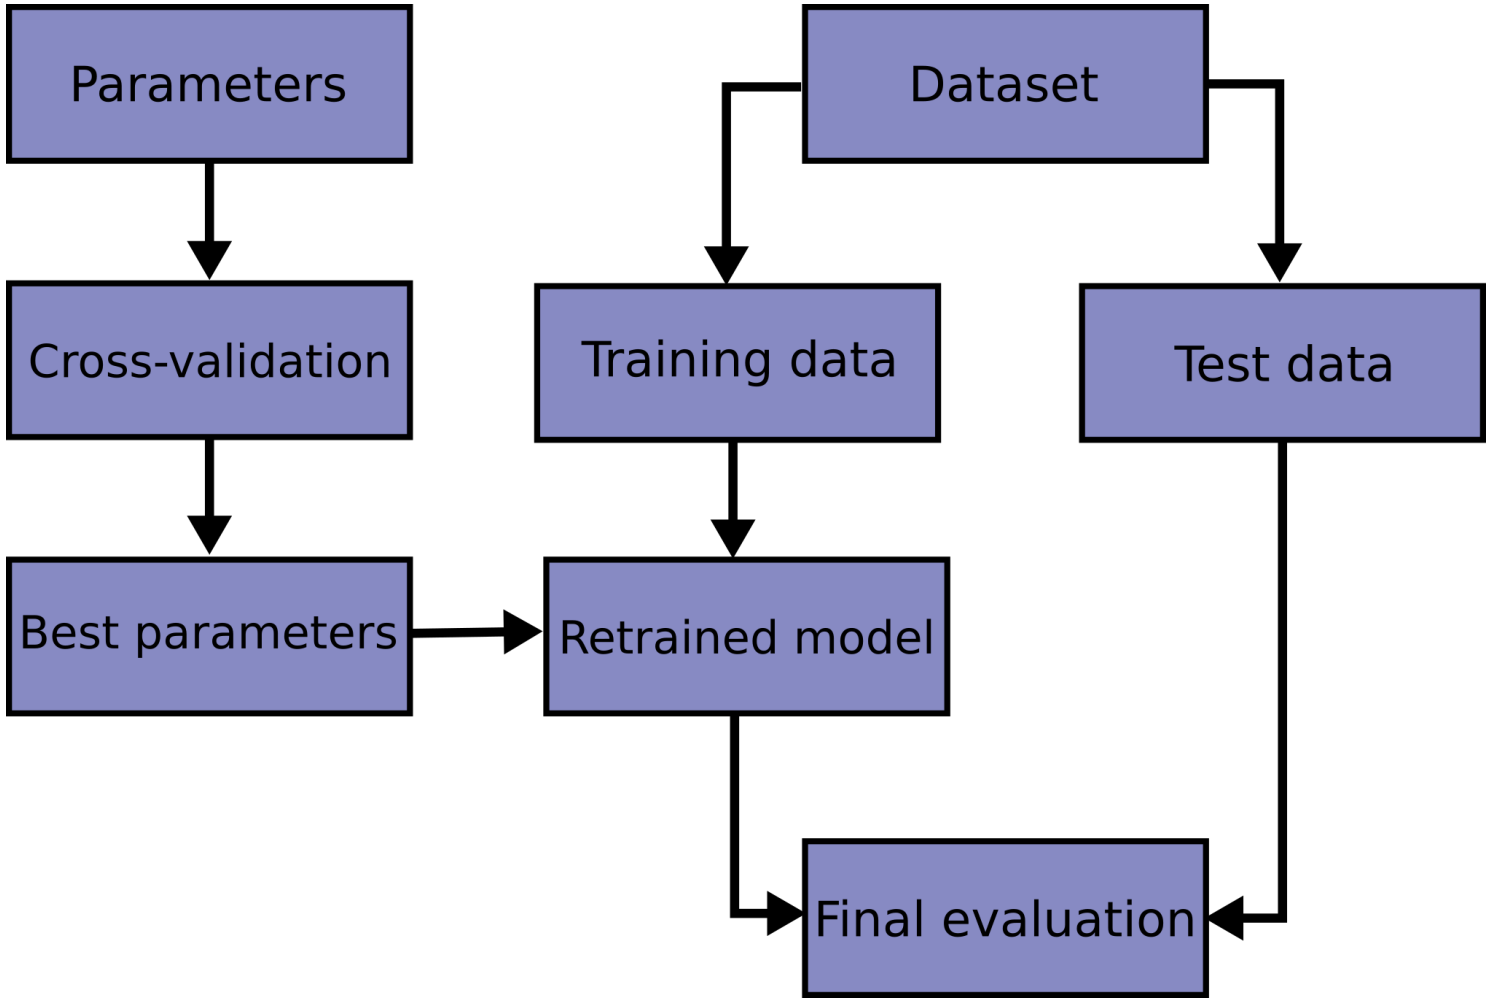

Hyperparameters

```
#GridSearchCV
parameters = {'kernel':('linear', 'rbf'), 'C':[1, 10]}
svc = svm.SVC(gamma="scale")
clf = GridSearchCV(svc, parameters, cv=5)
clf.fit(x, y)
sorted(clf.cv_results_.keys())

clf.best_estimator_
clf.best_params_
clf.best_score_
```

Hyperparameters

sklearn.model_selection.GridSearchCV

class `sklearn.model_selection.` **`GridSearchCV`** (*estimator*, *param_grid*, *scoring=None*, *fit_params=None*, *n_jobs=None*, *iid='warn'*, *refit=True*, *cv='warn'*, *verbose=0*, *pre_dispatch='2*n_jobs'*, *error_score='raise-deprecating'*, *return_train_score='warn'*) [source]

Confusion Matrix - דגשים לסיווג

		True condition				
	Total population	Condition positive	Condition negative	Prevalence $= \frac{\Sigma \text{ Condition positive}}{\Sigma \text{ Total population}}$	Accuracy (ACC) = $\frac{\Sigma \text{ True positive} + \Sigma \text{ True negative}}{\Sigma \text{ Total population}}$	
Predicted condition	Predicted condition positive	**True positive**, Power	**False positive**, Type I error	Positive predictive value (PPV), Precision = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Predicted condition positive}}$	False discovery rate (FDR) = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Predicted condition positive}}$	
	Predicted condition negative	**False negative**, Type II error	**True negative**	False omission rate (FOR) = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Predicted condition negative}}$	Negative predictive value (NPV) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Predicted condition negative}}$	
		True positive rate (TPR), Recall, Sensitivity, probability of detection $= \frac{\Sigma \text{ True positive}}{\Sigma \text{ Condition positive}}$	False positive rate (FPR), Fall-out, probability of false alarm $= \frac{\Sigma \text{ False positive}}{\Sigma \text{ Condition negative}}$	Positive likelihood ratio (LR+) $= \frac{\text{TPR}}{\text{FPR}}$	Diagnostic odds ratio (DOR) $= \frac{\text{LR+}}{\text{LR−}}$	F_1 score = $2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$
		False negative rate (FNR), Miss rate $= \frac{\Sigma \text{ False negative}}{\Sigma \text{ Condition positive}}$	Specificity (SPC), Selectivity, True negative rate (TNR) $= \frac{\Sigma \text{ True negative}}{\Sigma \text{ Condition negative}}$	Negative likelihood ratio (LR−) $= \frac{\text{FNR}}{\text{TNR}}$		

דגשים לסיווג - Confusion Matrix

	לקוחות עם קשיי תשלום	לקוחות ללא קשיי תשלום
חיזוי קשיי תשלום חיובי	59	12
חיזוי קשיי תשלום שלילי	34	150

- TP– 59, NT- 150, PF – 12, NF – 34
- Recall = 59/(59+34)

persicion = 59/(12 + 59)

Recall & percision - דגשים לסיווג

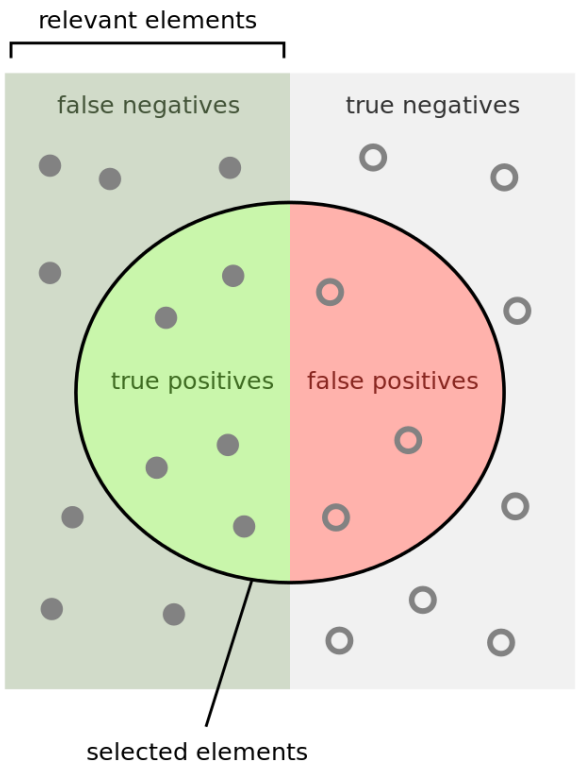

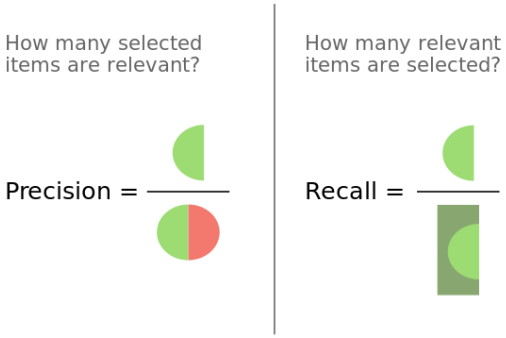

דגשים לסיווג

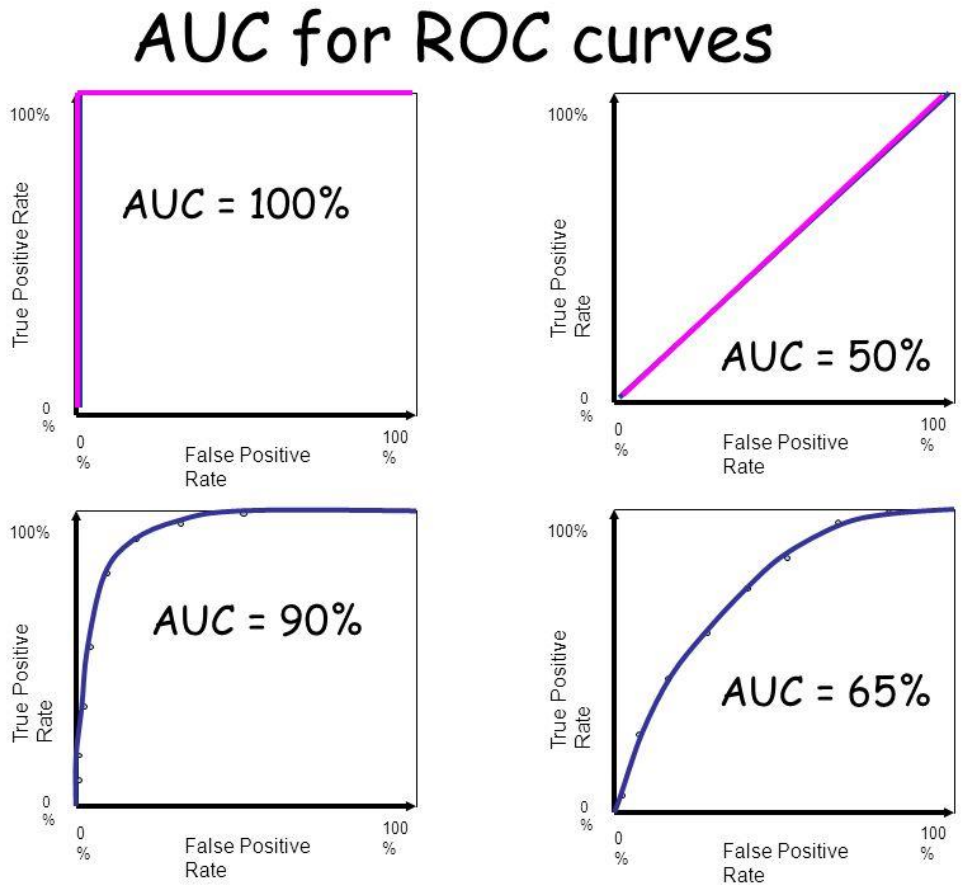

דגשים לסיווג

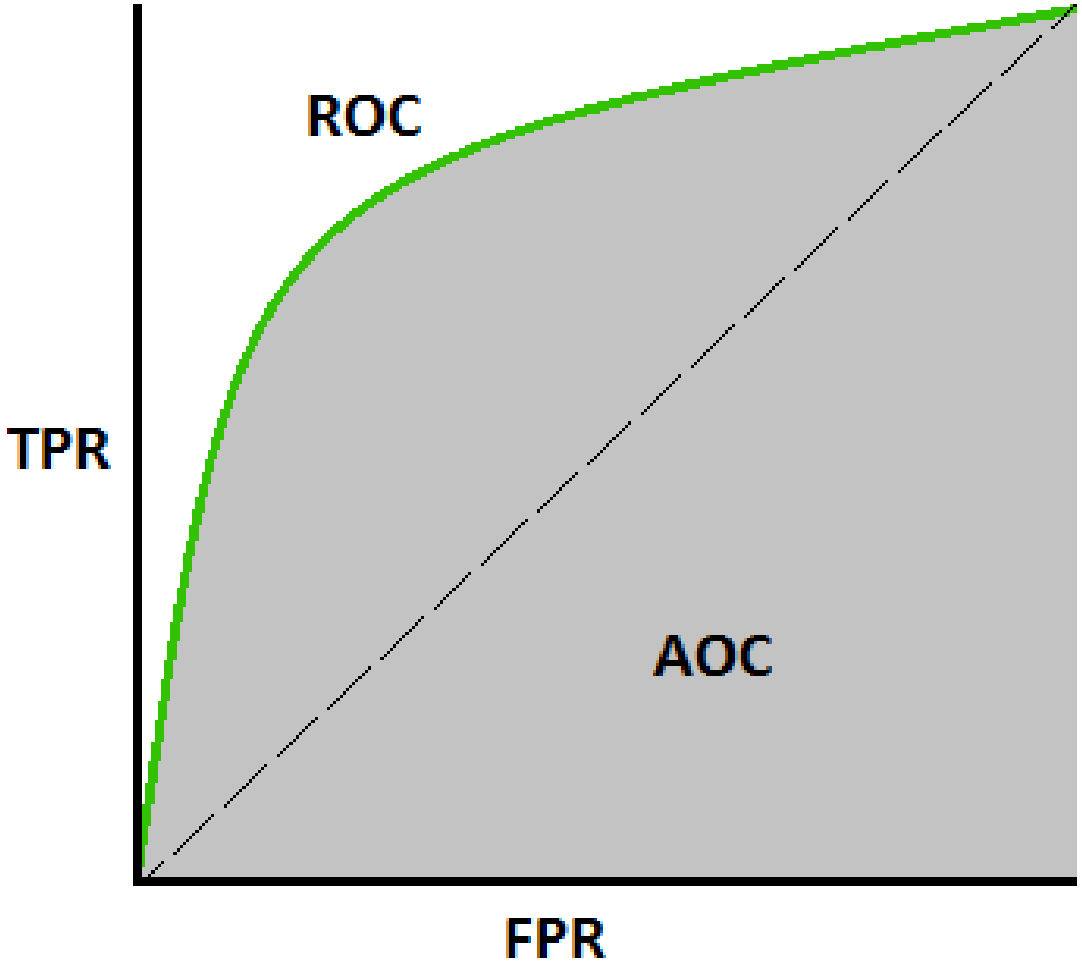

דגשים לסיווג

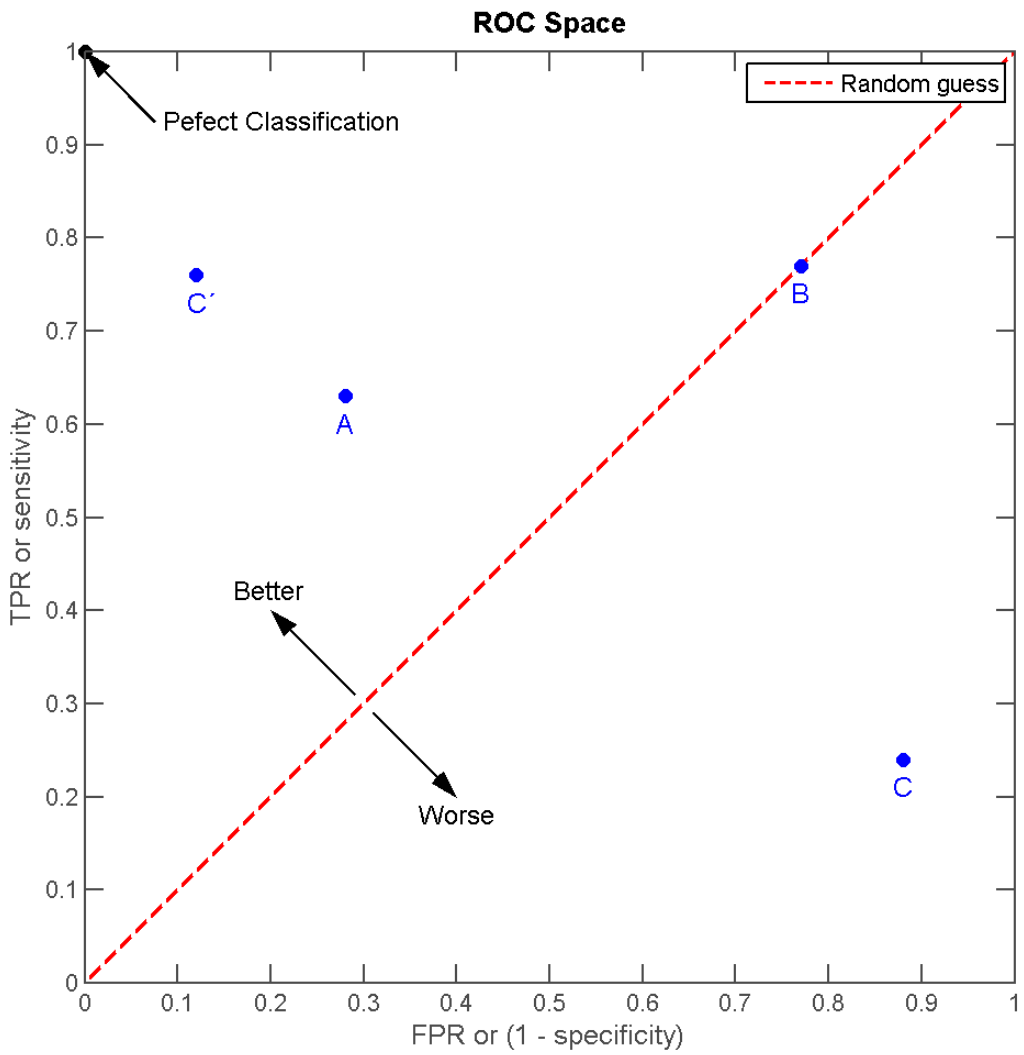

דגשים לסיווג

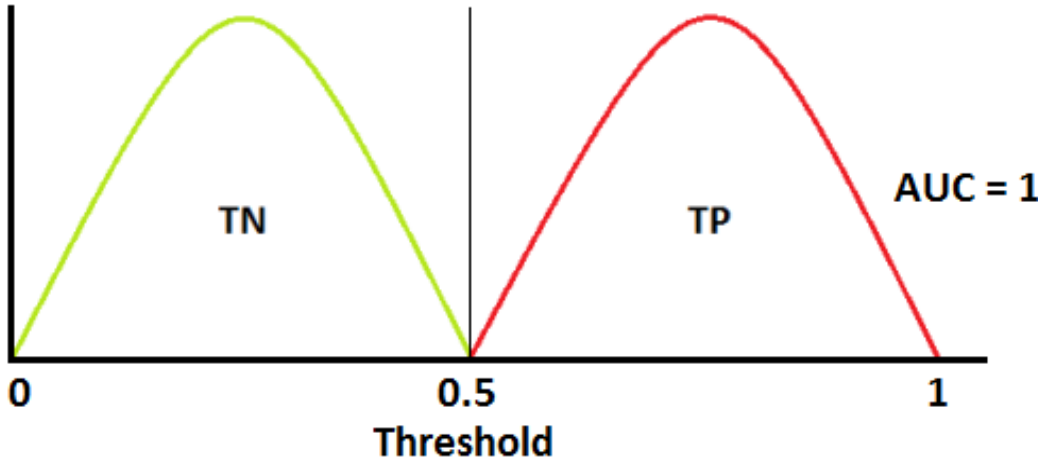

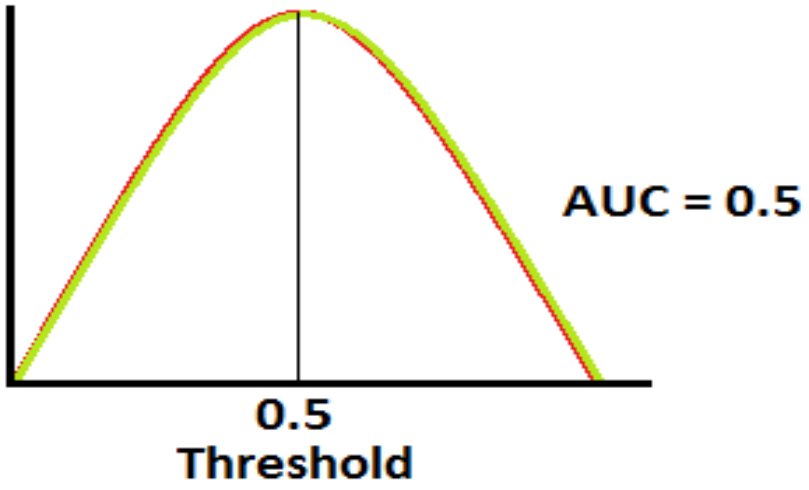

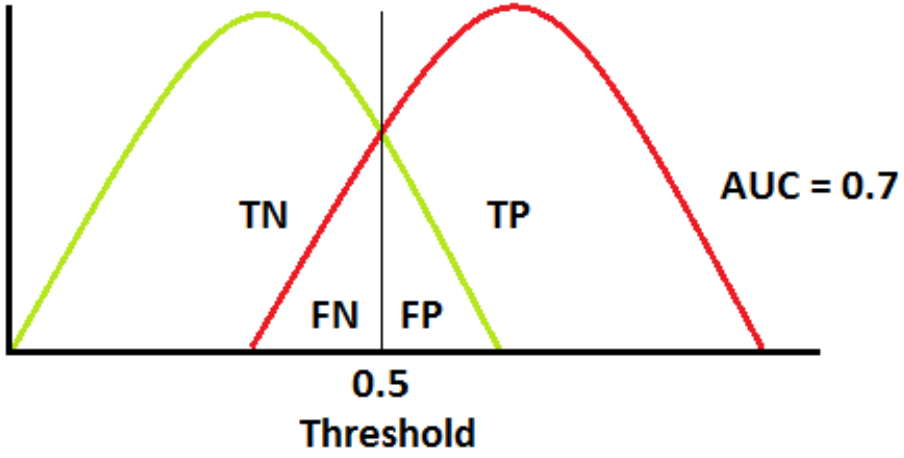

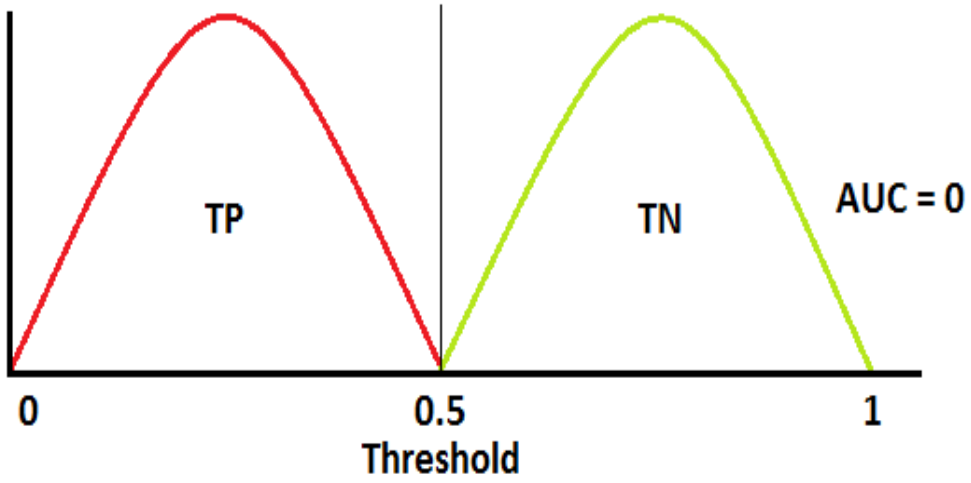

דגשים לסיווג - מימוש roc auc ב-python

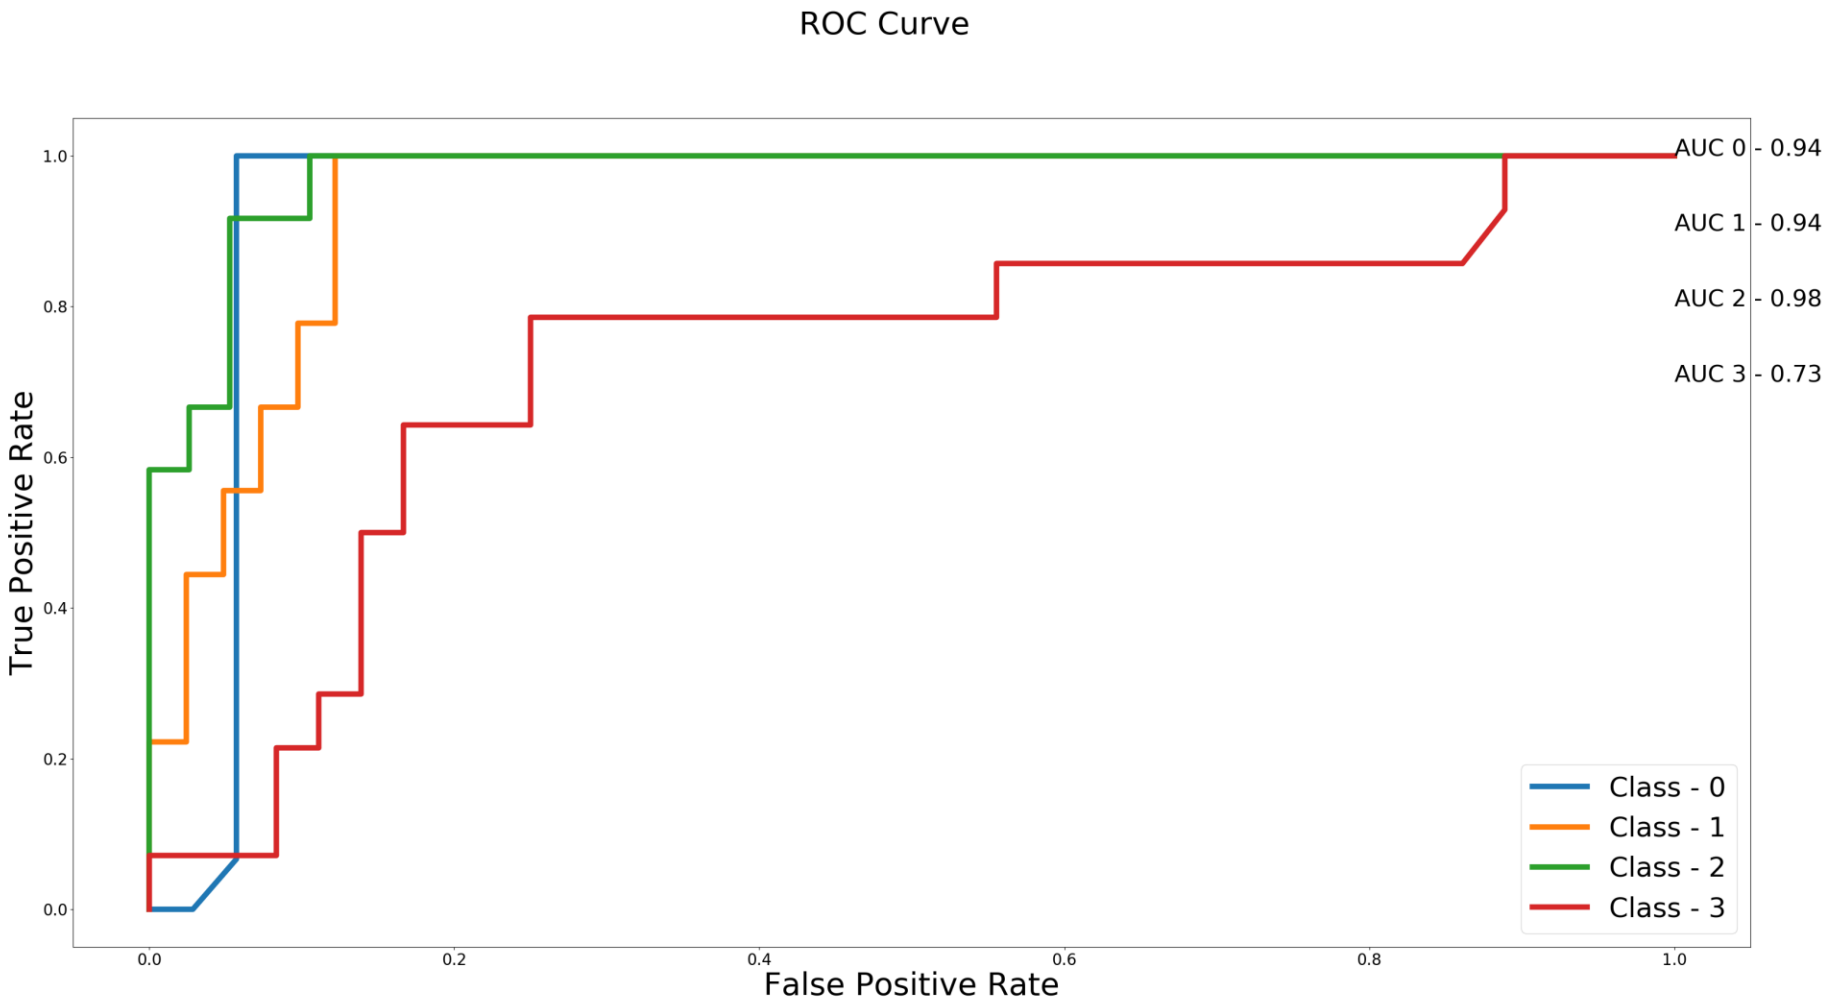

- הגרף מחושב עבור תנאי סף שונים והוא threshhold אינו ליניארי

Ensembles - חוכמת ההמונים

- Ensembles – שילוב של מספר מודלים מוצלחים, לקבלת תוצאה אופטימאלית
- Bagging (Bootstrap Aggregation) - אימון מודל זהה על דוגמאות שונות מתוך ה - training set
- Boosting - אימון מודל זהה על דוגמאות שונות מתוך ה- training set בשרשור, ומתן דגש על לימוד דוגמאות שסווגו לא נכון
- Blending (Stacking)– הכנסת תוצרי אימון של מודלים שונים כקלט ולימודם ע"י אלגוריתים חדש לקבלת תוצאה משוקללת

Bootstrap Aggregating

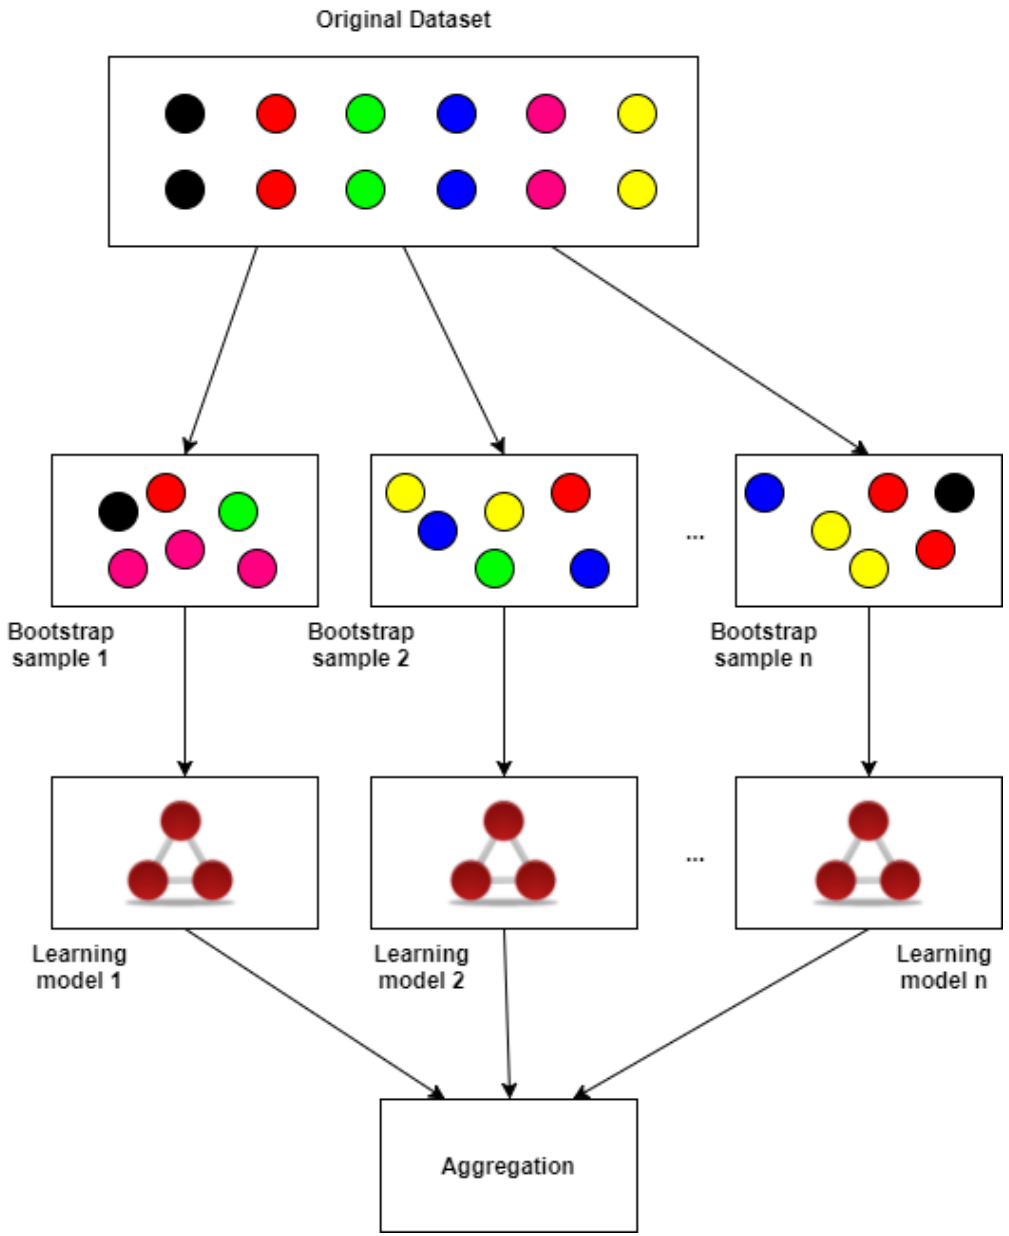

- הדוגמאות מחולקות לקבוצות קטנות, על כל קבוצה מבוצעת למידה
- לאחר אימון מתקבלים מודלים עליהם מבוצעת פעולת Aggregation
- במקרה של רגרסיה החיזוי יהיה ממוצע של כלל המודלים (soft)
- במקרה של קלסיפיקציה החיזוי יתבצע ע"י פעולת Voting (hard) או ממוצע על ההסתברויות (soft)
- RF הוא דוגמא למודל שעושה Bagging - כאשר התת מודל שלו זה עצי ההחלטה

מימוש Bootstrap Aggregating -

```
#Ensembles
x, y = load_iris(return_X_y=True)
x_new , y_new = put_anomaly(x,y,i_max=50)
x = x_new
y = y_new


X_train, X_test, y_train, y_test = train_test_split(
    x, y, test_size=0.33, random_state=42)

clf = RandomForestClassifier(n_estimators=100, max_depth=2,random_state=0)

bagging = BaggingClassifier(clf,max_samples=0.5, max_features=0.5)

clf.fit(X_train,y_train).score(X_test,y_test)
bagging.fit(X_train,y_train).score(X_test,y_test)
```

Bootstrap Aggregating

```
In [1291]: bagging.fit(X_train,y_train).score(X_test,y_test)
Out[1291]: 0.74

In [1292]: clf.fit(X_train,y_train).score(X_test,y_test)
Out[1292]: 0.62
```

Bootstrap Aggregating

sklearn.ensemble.BaggingClassifier

class sklearn.ensemble. **BaggingClassifier** (*base_estimator=None*, *n_estimators=10*, *max_samples=1.0*, *max_features=1.0*, *bootstrap=True*, *bootstrap_features=False*, *oob_score=False*, *warm_start=False*, *n_jobs=None*, *random_state=None*, *verbose=0*) [source]

Boosting

- מבוצע אימון כל פעם על חלק מהדוגמאות מתוך ה-Data Set
- לאחר האימון ניתן משקל לכל דוגמא כך שדוגמאות עליהם ניתן חיזוי שגוי יילמדו בפעמים הבאות
- באופן זה הדוגמאות השגויות מאומנות יותר וכך התוצאות משתפרות
- בסיום התהליך ניתן משקל גם למסווגים השונים
- קיימים סוגים שונים של אלגוריתמים Boosting בינהם: AdaBoost, LPBoost, XGBoost, GradientBoost, BrownBoost.
- מומלץ להשתמש ב-XGBoost

Boosting

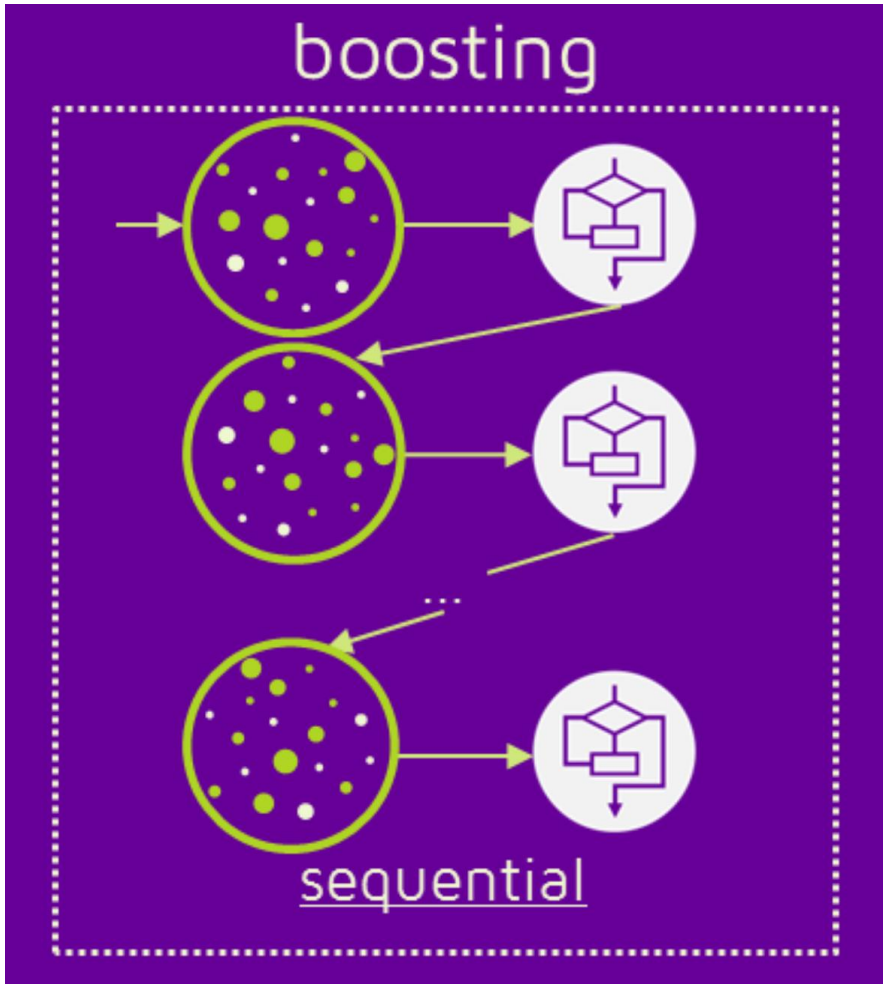
boosting
...
sequential

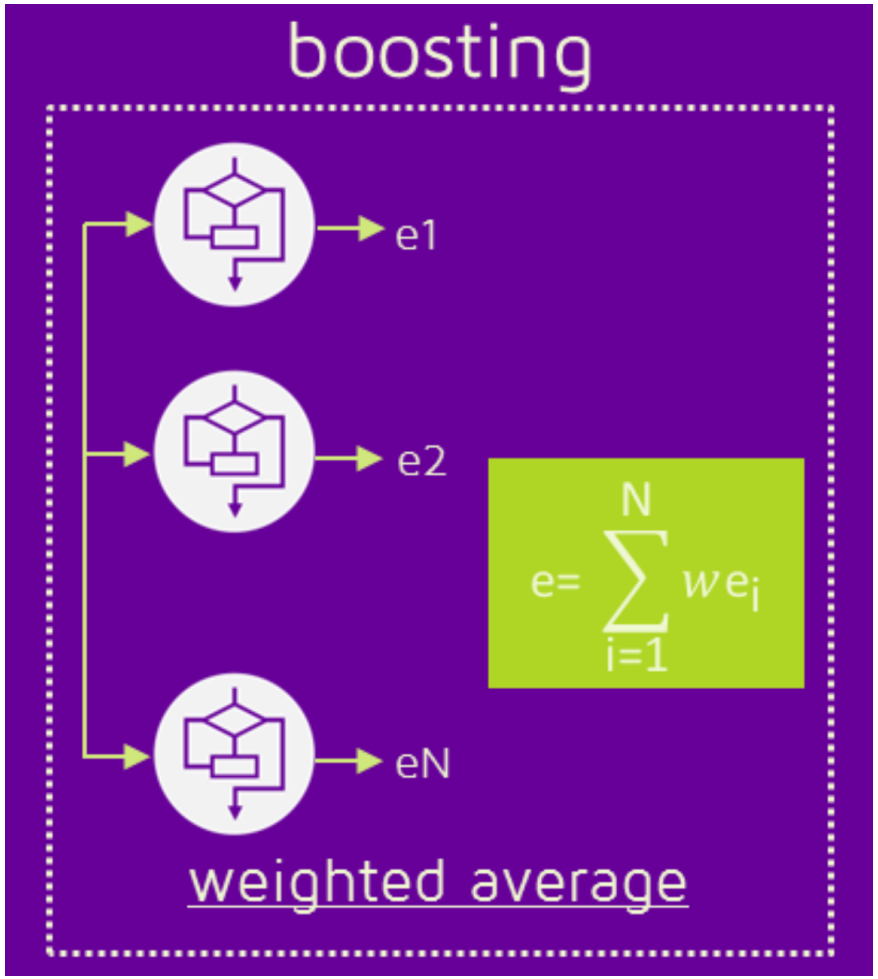
boosting
e1
e2
eN
$e = \sum_{i=1}^{N} w e_i$
weighted average

מימוש בפייתון- Boosting

```
#Boosting - AdaBoost
clf_boost = AdaBoostClassifier(clf,n_estimators=100)
clf_boost.fit(X_train,y_train).score(X_test,y_test)
```

Blending- Stacking

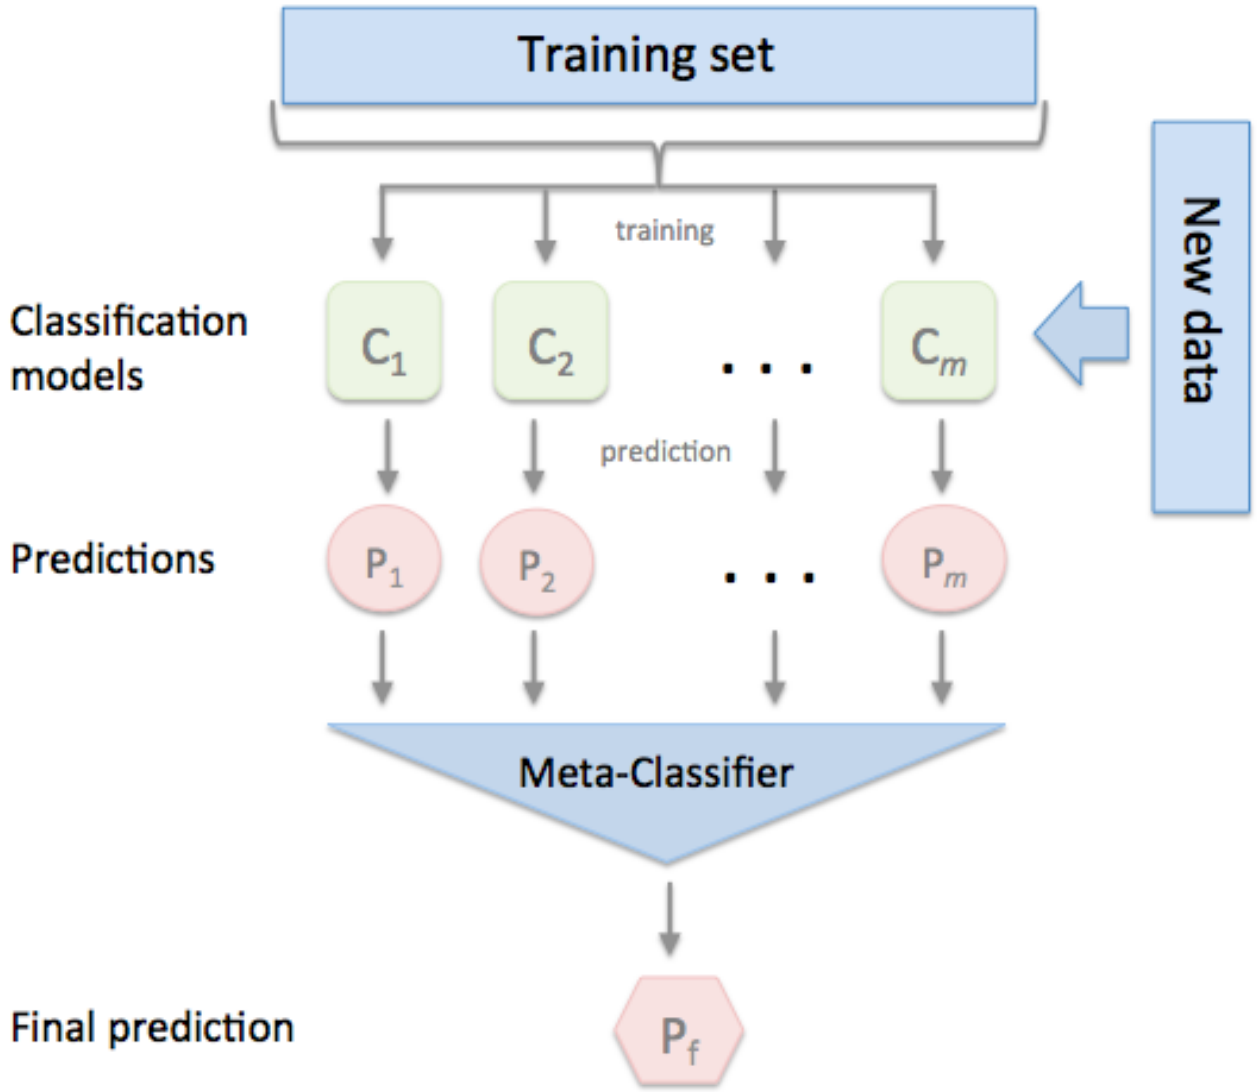

- בשיטה זו משתמשים במספר מסווגים שונים (meta-classifier) על כל ה- train data
- לבסוף ישנו אלגוריתים הלומד את התוצאות של מסווגים אלו, ונותן חיזוי המורכב מכלל התוצאות של הmeta-classifier
- האימון יכול להיות על הסיווג עצמו או על ההסתברויות שמתקבלות מהסיווג

Blending

```
#Blending
model1 = RandomForestClassifier()
model2 = KNeighborsClassifier()
model3= LogisticRegression()

clf_voting = VotingClassifier(estimators=[
        ('RandomForestClassifier', model1), ('KNeighborsClassifier', model2),
('LogisticRegression', model3)], voting='hard')#'soft'


clf_voting.fit(X_train,y_train).score(X_test,y_test)
```

Ensemble

- decrease model variance – Bagging
- decrease model bias – Boosting
- increase predictive force of the classifier – Blending